

Неделя 1

Базовые понятия обучения с подкреплением

Обучение с подкреплением — это метод машинного обучения, при котором алгоритм (агент) учится принимать оптимальные решения, взаимодействуя с окружающей средой методом проб и ошибок. Агент получает награды или штрафы за свои действия, стремясь максимизировать суммарное вознаграждение.

Процесс строится на взаимодействии двух сущностей: агента и окружающей среды:

1. Агент (agent) – это алгоритм или сущность, которая принимает решения и совершает действия.
2. Среда (environment) – это внешний мир или система, в которой действует агент. Он ничего не знает о ней, а только получает новые состояния и награды в ответ на действия. Взаимодействие между агентом и средой происходит в циклическом режиме:
3. Действие (Action, a): агент совершает шаг (например, показывает баннер пользователю).
4. Состояние (State, s): среда сообщает агенту информацию о текущей ситуации (например, характеристики пользователя в интернете). Важно, что вероятность перехода в следующее состояние зависит только от текущего состояния и действия, а не от всей предыдущей истории (Марковское предположение).
5. Награда (Reward, r): среда дает числовую обратную связь, оценивающую качество последнего действия (например, кликнул ли пользователь на баннер). Улучшение стратегии (Policy, $\pi(a|s)$): правило, по которому выбирается действие в конкретном состоянии

Метод кросс-энтропии

Метод кросс-энтропии (Crossentropy method, CEM) – метод стохастической оптимизации (эволюционный алгоритм), который используется для поиска оптимального решения в задачах с редкими наградами, в том числе в обучении с подкреплением.

Табличный метод кросс-энтропии

Этот подход применяется в задачах с небольшим количеством состояний и действий. Стратегия $\pi(a, s)$ описывается как матрица вероятностей следующего вида:

$$\pi(a, s) = A_{s,a}$$

$$E = \{(a_0, s_0), \dots, (a_k, s_k)\}$$

$$\pi(a, s) = \frac{\sum_{s_t, a_t \in E} [s_t = s][a_t = a]}{\sum_{s_t, a_t \in E} [s_t = s]}$$

Нейросетевой метод кросс-энтропии

Идея состоит в том, чтобы использовать нейронную сеть для аппроксимации стратегии. На каждом шаге действия выбирается с помощью предсказания сети. Сеть максимизирует правдоподобие из элитных сессий $\pi = \arg \max \sum_{s_i, a_i \in E} \log \pi(a_i, s_i)$.

Неделя 2

$V(s), Q(s, a)$

$V(s)$ – функция стоимости состояния (state-value function) – это математическое ожидание суммарного дохода, который агент может получить, начиная с состояния s и далее следуя своей политике π .

$$v_{\pi}(s) = E_{\pi}[G_t | S_t = s] = \sum_a \pi(a|s) \sum_{r, s'} p(r, s' | s, a) [r + \gamma v_{\pi}(s')] \quad (1)$$

Интуитивный смысл $V(s)$ заключается в том насколько выгодно для агента находиться в данном состоянии s , если он будет продолжать действовать согласно своей текущей политике π .

$Q(s, a)$ – функция состояния и действия (action-value function) – это ожидаемое вознаграждение, которое агент получит, если в состоянии s он сначала совершит конкретное действие a , а во всех последующих состояниях будет придерживаться политики π .

$$q_{\pi}(s, a) = E_{\pi}[G_t | S_t = s, A_t = a] = \sum_{r, s'} p(r, s' | s, a) [r + \gamma v_{\pi}(s')] \quad (2)$$